

Université Libre de Bruxelles
Faculté des Sciences — Département d'Informatique

Détection de communautés dans DBLP

Rapport de projet
INFO-F-203 — Algorithmique 2
Année académique 2025/2026

Binôme :
Chaabane Youssef 000574459
El Haichami Ilyas 000532152

Bruxelles, avril 2026

Table des matières

1 Introduction **2**

2 Méthodologie **2**

2.1 Tâche 1 – Communautés de co-publication (graphe non orienté) 2

2.2 Tâche 2 – CFC dans un graphe orienté filtré 2

3 Résultats **3**

3.1 Tâche 1 3

3.2 Tâche 2 3

4 Discussion **4**

5 Conclusion **4**

1 Introduction

La base de données DBLP [2] recense les publications scientifiques en informatique. Ce projet analyse un snapshot du 1er janvier 2026 contenant **7 995 940 publications** et **4 031 750 auteurs distincts**, traités en *flux* (online), publication par publication. L'objectif est d'identifier des communautés de chercheurs selon deux approches : (1) des communautés de co-publication dans un graphe non orienté, maintenues dynamiquement via Union-Find ; (2) des composantes fortement connexes (CFC) dans un graphe orienté filtré par un seuil minimal de co-publications.

2 Méthodologie

La Figure 1 présente l'architecture globale du pipeline.

2.1 Tâche 1 – Communautés de co-publication (graphe non orienté)

Modèle. Chaque auteur est un sommet, identifié par son nom tel que fourni par DBLP. Une arête non orientée relie A et B s'ils ont co-signé au moins une publication. Une communauté correspond à une composante connexe de ce graphe.

Structure de données. Une structure *Union-Find* [1, chap. 2] (tableaux `parent[]`, `height[]` et `sz[]`) maintient les composantes connexes de manière online. Deux optimisations du cours sont combinées : *union pondérée par hauteur* [1, § 2.3] et *compression de chemin complète* en deux passes [1, § 2.4] (voir Figure 2). Un compteur `numComponents` est décrémenté à chaque union effective.

Traitement online. À chaque publication $[A, B_1, \ldots, B_k]$, on exécute `union`(A, B_i) pour tout $i \geq 1$, plaçant tous les co-auteurs dans la même composante par transitivité. Les éventuels doublons de noms au sein d'une même publication sont ignorés. Toutes les 10^5 publications, le programme affiche le nombre total de communautés et les tailles des 10 plus grandes, obtenues via un *min-heap* [1, chap. 4] de taille 10 parcouru en $O(N)$.

Complexité. Temps : $O(P \cdot k_{\text{moy}} \cdot \alpha(N))$ amorti, où P est le nombre de publications, k_{moy} le nombre moyen d'auteurs par publication et α la fonction inverse d'Ackermann (quasi-constante en pratique [1, § 2.4]). Espace : $O(N)$ pour les tableaux `parent`, `height` et `sz`.

2.2 Tâche 2 – CFC dans un graphe orienté filtré

Modèle. Pour chaque publication ayant au moins 2 auteurs, le premier auteur A incrémente online un compteur $c(A \to B)$ pour chaque co-auteur B (via une `HashMap<Long, Integer>`, la paire étant encodée dans un `long`). Cette phase de comptage est *véritablement online* ; le calcul des CFC (Kosaraju) s'effectue en batch après la lecture complète du flux. Après le parsing, on conserve l'arête $A \to B$ si et seulement si $c(A \to B) \geq 6$ (seuil choisi pour ne retenir que des collaborations répétées ; sa valeur influe directement sur la taille et le nombre des CFC). Seuls les auteurs ayant au moins une arête dans ce graphe filtré sont des sommets ; les auteurs isolés n'appartiennent à aucune communauté. Une communauté est une CFC de ce graphe orienté filtré.

Algorithme de Kosaraju. Les CFC sont calculées par l'algorithme de Kosaraju [1, chap. 7] : une première passe DFS sur le graphe original produit un ordre de fin des sommets ; une seconde passe DFS sur le graphe transposé, dans l'ordre inverse de fin, collecte les CFC. Les deux DFS [1, chap. 6] sont implémentés de façon *itérative* (pile explicite `ArrayDeque`) afin d'éviter tout débordement de pile sur un graphe de plusieurs millions de nœuds.

Diamètre. Pour chacune des 10 plus grandes CFC, le diamètre est calculé par BFS [1, chap. 6] depuis chaque sommet de la CFC, en ne suivant que les arêtes restant dans le sous-graphe induit. Un tableau de distances est réutilisé entre les BFS pour limiter les allocations mémoire.

Complexité. Comptage online : $O(P \cdot k_{\text{moy}})$, amorti $O(1)$ par paire grâce au hachage. Construction du graphe filtré : $O(E_{\text{total}})$ où E_{total} est le nombre de paires distinctes suivies

(11 834 881). Kosaraju : $O(N_{\text{actif}} + M_{\text{filtré}})$. Diamètre (top 10) : $O\Big(\sum_{i=1}^{10} |C_i| \cdot (|C_i| + |E_{C_i}|)\Big)$. Espace total : $O(N + E_{\text{total}})$.

Choix d'implémentation. Trois décisions techniques méritent d'être soulignées : (1) les paires orientées sont encodées dans un `long` plutôt que dans un objet, évitant des millions d'allocations ; (2) les deux DFS de Kosaraju sont itératifs (pile `ArrayDeque` explicite) pour éviter un `StackOverflowError` sur des millions de nœuds ; (3) le tableau de distances du BFS est réutilisé par réinitialisation sélective des seules cases modifiées, réduisant les allocations mémoire.

3 Résultats

3.1 Tâche 1

Sur les 7 995 940 publications lues, le programme identifie **169 659 communautés** pour 4 031 750 auteurs (voir Figure 3). La distribution suit une loi de puissance : 104 904 communautés sont des singletons (auteurs sans co-auteur), tandis qu'une unique *composante géante* regroupe **3 734 901 auteurs** (soit 92,6 % de l'ensemble des auteurs). Le Tableau 1 illustre l'évolution online des communautés au fil du flux, démontrant la mise à jour incrémentale à chaque palier de 10^5 publications.

Table 1 – États intermédiaires affichés sur le terminal (Tâche 1).

Publications lues	Nb. communautés	Top 3 tailles		
100 000	17 951	81 800	268	83
500 000	39 779	552 383	92	45
1 000 000	54 015	977 552	88	73
4 000 000	103 728	2 454 219	56	55
7 995 940	169 659	3 734 901	54	48

3.2 Tâche 2

Après filtrage (seuil ≥ 6), le graphe orienté contient **272 861 auteurs** et **358 861 arêtes**. L'algorithme de Kosaraju identifie **260 206 CFC** (voir Figure 4), dont 252 093 singletons et 8 113 de taille ≥ 2. Le Tableau 2 détaille les 10 plus grandes CFC.

Table 2 – Les 10 plus grandes CFC – taille et diamètre (Tâche 2).

Rang	Taille	Diamètre
1	133	30
2	73	35
3	38	13
4	34	7
5	33	6
6	30	17
7	27	10
8	26	12
9	23	6
10	21	7

4 Discussion

Cohérence des résultats avec les attentes. La composante géante de la Tâche 1 (92,6 % des auteurs) est cohérente avec les propriétés connues des réseaux de collaboration scientifique, où la quasi-totalité des chercheurs actifs sont reliés par des chaînes de co-authorship – phénomène analogue à celui observé sur l'internet ou dans les réseaux sociaux. La distribution des tailles en loi de puissance (Figure 3) est également caractéristique de ces réseaux. Pour la Tâche 2, le seuil élevé (≥ 6) filtre les collaborations ponctuelles et ne retient que des relations fortes et répétées ; les 8 113 CFC non triviales correspondent à des équipes ou des communautés thématiques stables. On note que la CFC #2 (73 membres) présente un diamètre de 35 supérieur à celui de la CFC #1 (133 membres, diamètre 30), ce qui indique une structure plus linéaire dans le second groupe.

Limites de l'implémentation. L'identification des auteurs repose uniquement sur leur nom ; des homonymes sont donc fusionnés en une seule entité, ce qui peut artificiellement agrandir certaines communautés ou fausser les compteurs de paires. Par ailleurs, l'exécution complète requiert environ 6 Go de mémoire vive et 68 secondes sur la machine de test.

Passage à l'échelle (OpenAlex, ≈480M publications, 120M auteurs). Le volume de données serait environ 60× plus grand. L'Union-Find resterait applicable en théorie, mais ses tableaux (120M entrées) nécessiteraient une implémentation distribuée (ex. Apache Spark) ou stockée sur disque. La `HashMap pairCounts` pourrait atteindre plusieurs milliards d'entrées ; il faudrait recourir au tri externe ou à des structures approximatives (ex. Count-Min Sketch). L'algorithme de Kosaraju nécessite deux passes complètes sur le graphe ; pour ce volume, un algorithme de CFC semi-externe serait préférable.

5 Conclusion

Ce projet a mis en œuvre deux algorithmes fondamentaux [1] – Union-Find et Kosaraju – sur un flux réel de près de 8 millions de publications scientifiques. La Tâche 1 révèle une composante géante regroupant 92,6 % des auteurs actifs, caractéristique des réseaux de co-authorship. La Tâche 2 identifie 8 113 groupes de collaboration forte et mutuellement fermés parmi les 272 861 auteurs du graphe filtré. Les résultats sont cohérents avec les propriétés attendues de ce type de réseau. Une piste d'amélioration serait de rendre le seuil paramétrable et d'étudier la sensibilité des CFC à sa variation. Pour des bases de données de la taille d'OpenAlex, des approches distribuées et des algorithmes de CFC semi-externes seraient indispensables.

Références

[1] *Notes de cours INFO-F-203 – Algorithmique 2*, Université Libre de Bruxelles, 2025/2026. Chapitres 2 (Union-Find), 4 (Files de priorité), 6 (DFS/BFS), 7 (CFC/Kosaraju).

[2] M. Ley. *DBLP : Some Lessons Learned.* Proc. VLDB Endow., 2(2) :1493–1500, 2009.

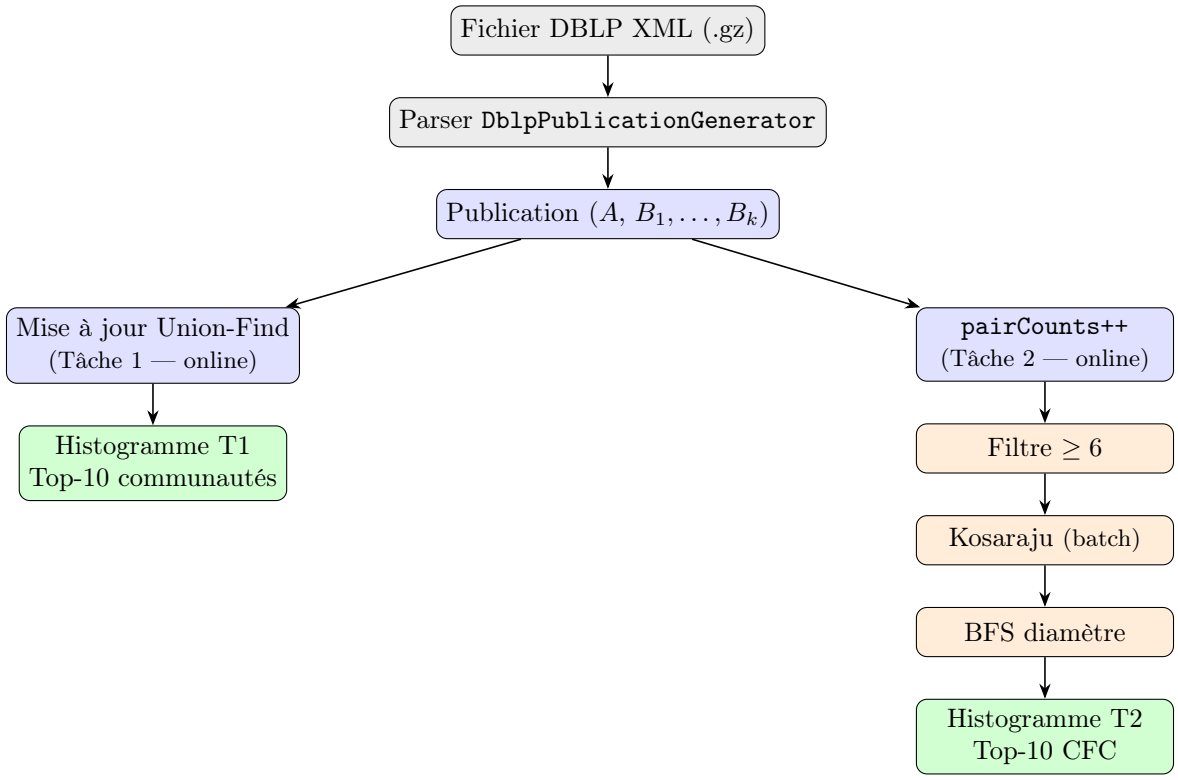


FIGURE 1 – Architecture du pipeline de traitement DBLP. Cases bleues : traitement *online* (mis à jour publication par publication). Cases oranges : traitement *batch* (après lecture complète du flux).

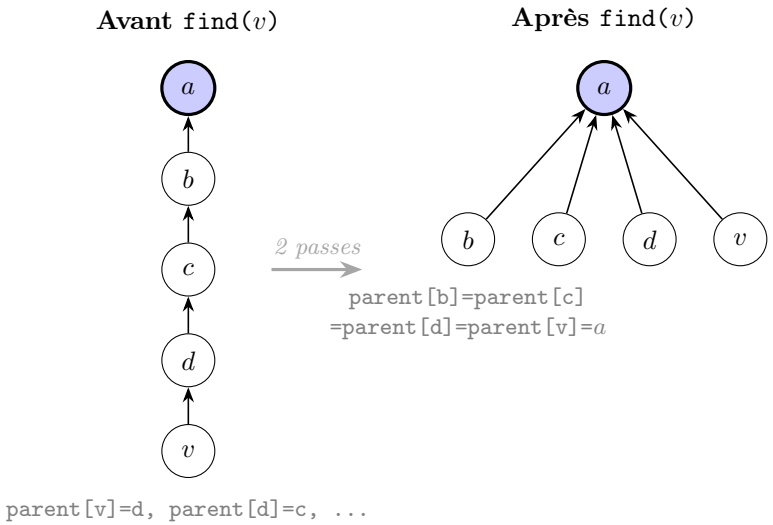


FIGURE 2 – Compression de chemin complète (§ 2.4 du cours). La 1re passe remonte jusqu'à la racine a ; la 2e passe rattache directement chaque nœud du chemin à a, aplatissant l'arbre.

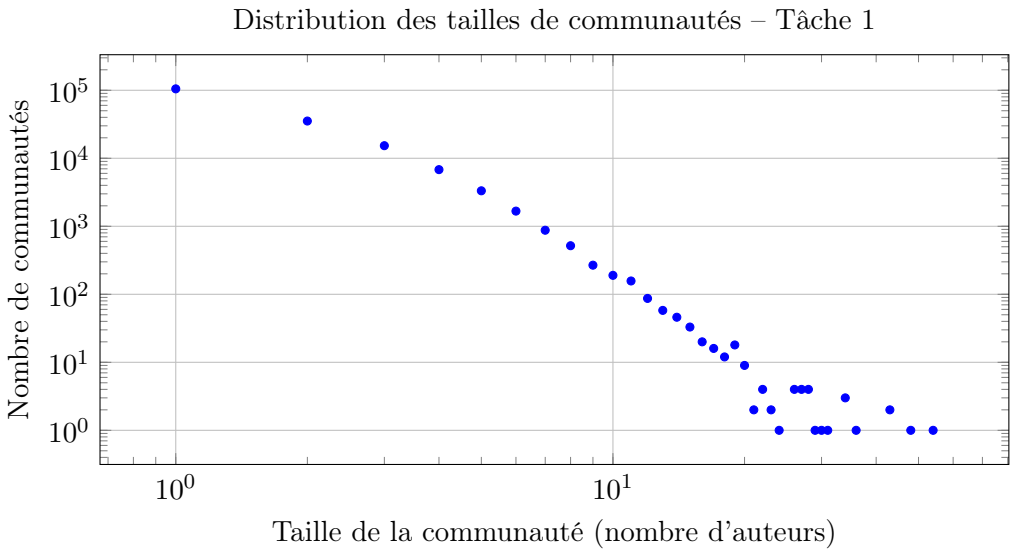


FIGURE 3 – Histogramme des tailles des communautés de co-publication (Tâche 1, échelle log-log). La composante géante de 3 734 901 membres est exclue du graphique pour des raisons d'échelle.

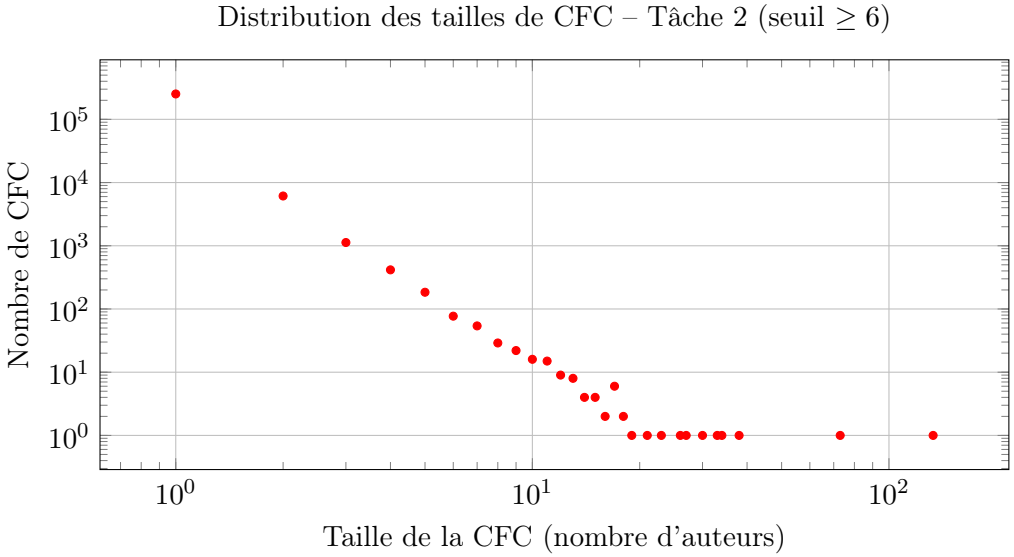


FIGURE 4 – Histogramme des tailles des CFC (Tâche 2, échelle log-log). Graphe orienté filtré avec seuil ≥ 6 co-publications.